

Detecção de Degradação Dinâmica em Drones a partir de Dados de Odometria

March 18, 2026

1 Introdução

Este trabalho apresenta uma abordagem para inferir a saúde do sistema de propulsão e controle de drones utilizando exclusivamente dados de odometria (posição e velocidade), sem acesso a sensores internos como RPM, ESC ou dados confiáveis de bateria.

A motivação principal é investigar se é possível detectar falhas ou degradações do sistema a partir de assinaturas dinâmicas do movimento, isto é, analisando como o drone se move no espaço ao longo do tempo.

A proposta trata o drone como um sistema dinâmico observável, no qual falhas internas se manifestam como alterações na resposta do movimento.

2 Dados e Pré-processamento

Foram utilizados 47 voos do dataset ALFA. Cada voo contém registros de:

- posição (x, y, z) ,
- velocidade linear (v_x, v_y, v_z) ,
- tempo.

Inicialmente, os dados de bateria foram considerados, mas verificou-se que todos os voos apresentavam valores inválidos. A corrente estava próxima de zero e tensão era zero. Dessa forma, a análise foi conduzida exclusivamente com base em variáveis cinemáticas.

Para cada voo, foi construído um arquivo consolidado contendo:

- tempo normalizado,
- posição,
- velocidade,
- velocidade escalar.

3 Modelagem Dinâmica

A partir das velocidades, foram calculadas derivadas temporais para obter métricas dinâmicas fundamentais.

3.1 Aceleração

A aceleração foi estimada como:

$$a = \frac{dv}{dt}$$

Componentes:

- $a_x = \frac{dv_x}{dt}$
- $a_y = \frac{dv_y}{dt}$

A aceleração total foi definida como:

$$a_{\text{total}} = \sqrt{a_x^2 + a_y^2}$$

3.2 Decomposição da Aceleração

A aceleração foi decomposta em duas componentes:

Aceleração longitudinal

$$a_{\text{long}} = \frac{v_x a_x + v_y a_y}{\sqrt{v_x^2 + v_y^2}}$$

Representa a variação de velocidade na direção do movimento.

Aceleração lateral

$$a_{\text{lat}} = \frac{v_x a_y - v_y a_x}{\sqrt{v_x^2 + v_y^2}}$$

Representa a curvatura da trajetória e está diretamente associada à capacidade de manobra.

3.3 Jerk

O jerk foi calculado como a derivada da aceleração:

$$j = \frac{da}{dt}$$

Essa métrica mede a suavidade do movimento e é amplamente utilizada em sistemas robóticos para identificar irregularidades dinâmicas.

4 Features Extraídas

Para cada voo, foram extraídas as seguintes métricas:

- média da aceleração total (a_{total}),
- média da aceleração lateral (a_{lat}),
- desvio padrão das acelerações,
- média e variabilidade do jerk,
- razão entre aceleração lateral e total:

$$\text{lat_ratio} = \frac{\langle |a_{\text{lat}}| \rangle}{\langle a_{\text{total}} \rangle}$$

4.1 Importância Física das Variáveis

- a_{total} : mede o esforço dinâmico global do sistema. Reduções indicam perda de capacidade de resposta.
- a_{lat} : mede a capacidade de manobra. Valores menores indicam dificuldade em corrigir trajetória.
- lat_ratio : indica quanto do movimento é lateral. Está diretamente ligado ao controle ativo do drone.
- jerk : mede a suavidade da resposta. Variações elevadas indicam comportamento irregular.

5 Score de Saúde do Motor

Foi definido um score baseado no desvio das features em relação a voos sem falha.

- baseline: voos classificados como `no_failure`,
- normalização via mediana e MAD,
- penalização de valores abaixo do padrão.

Esse score representa o grau de degradação dinâmica do voo.

6 Modelagem com Machine Learning

Foi treinado um classificador Random Forest utilizando:

- a_{lat} ,
- a_{total} ,
- lat_ratio .

O modelo foi treinado para distinguir:

- voos com falha de motor,
- voos sem falha.

6.1 Resultados

- acurácia: aproximadamente 70%,
- melhor desempenho na detecção de falhas,
- maior dificuldade em identificar voos normais.

A importância das features mostrou contribuição equilibrada entre as variáveis, indicando que a degradação é um fenômeno multifatorial.

7 Generalização para Dados Não Rotulados

O modelo foi aplicado a voos sem rótulo e a voos com outros tipos de falha (ailerons, rudder, elevator).

Observou-se que:

- o modelo identificou corretamente vários desses voos como anômalos,
- mesmo sem ter sido treinado para esses tipos de falha.

8 Principais Conclusões

- Falhas no drone se manifestam como redução da capacidade dinâmica, e não necessariamente como aumento de instabilidade.
- Métricas baseadas em aceleração e jerk são suficientes para capturar assinaturas de degradação.
- O modelo aprende padrões gerais de perda de controlabilidade, e não apenas falhas específicas de motor.
- É possível detectar anomalias sem acesso a sensores internos do sistema.
- A abordagem generaliza para falhas não vistas durante o treinamento.

9 Conclusão

Este trabalho demonstra que a análise da dinâmica do movimento é uma ferramenta poderosa para inferir a saúde de sistemas aeroespaciais.

Mesmo com dados limitados, foi possível construir um pipeline completo de:

- engenharia de features físicas,
- modelagem estatística,
- aprendizado de máquina,
- detecção de anomalias.

Os resultados indicam que a dinâmica do voo contém informação suficiente para identificar degradações relevantes, abrindo caminho para aplicações em monitoramento e diagnóstico de sistemas reais.