

1 Higienização e Padronização do Dataset ALFA

1.1 Estrutura Inicial

O dataset ALFA é composto por 48 voos, organizados em subpastas distintas, totalizando inicialmente 1591 arquivos no formato `.csv`. Cada voo contém múltiplos registros provenientes de diferentes tópicos MAVROS, incluindo sensores inerciais, estado da bateria, posição global e local, comandos de controle, navegação e status de falhas.

Os arquivos estavam organizados na seguinte estrutura:

```
/processed_csv/processed/  
carbonZ_<data>_<tipo_de_voo>/  
*.csv
```

1.2 Criação de Base Higienizada

Criamos uma nova estrutura espelhada no nome dado às pastas do ALFA dataset. Ela foi denominada:

```
/processed_csv/processed_higienizado/
```

Cada um dos 48 voos foi replicado nessa nova pasta, mantendo a mesma organização hierárquica, porém contendo arquivos já tratados.

1.3 Protocolo de Higienização de Dados

O tratamento dos arquivos `.csv` seguiu um fluxo padronizado para garantir a integridade e a homogeneidade da base. Inicialmente, as colunas passaram por uma normalização semântica, convertendo os nomes para o padrão `snake_case`, com letras minúsculas e remoção de caracteres especiais ou espaços. Símbolos técnicos, como o `o%`, foram substituídos por representações textuais para evitar erros de interpretação em pacotes de análise subsequentes.

Com relação à estrutura do dataset, procedemos com a exclusão de ruídos de exportação, como colunas do tipo `Unnamed`, e a remoção sistemática de variáveis com 100% de valores nulos. Para assegurar a unicidade e a confiabilidade dos registros, linhas integralmente duplicadas foram eliminadas, seguidas de uma reordenação temporal rigorosa sempre que o campo cronológico estava disponível.

Especificamente nos registros de `mavros-battery.csv`, as seguintes variáveis estruturais, desconhecidas pelo firmware, foram removidas por não agregarem valor analítico:

```
field_header_frame_id  
field_charge  
field_capacity  
field_design_capacity  
field_location  
field_serial_number
```

Apesar dessas variáveis fazerem parte da definição ROS `sensor_msgs/BatteryState`, elas não são preenchidas nos voos do ALFA.

1.4 Tratamento de Arquivos Inválidos

Na triagem inicial, identificou-se apenas um arquivo corrompido ou vazio (0 bytes), o qual foi descartado sem prejuízo à representatividade da amostra. Com a exclusão deste item, a base consolidada passou a contar com 1.549 arquivos válidos para análise.

1.5 Qualidade Estatística da Base Consolidada

O diagnóstico pós-higienização revela uma base de dados robusta e com baixa incidência de ruído. A média de valores nulos fixou-se em 3,27%, enquanto a mediana de 0% indica que a grande maioria dos arquivos está integralmente preenchida.

Reforçando essa consistência, 75% da amostra apresenta menos de 0,82% de dados ausentes. O valor máximo de lacunas observado (37,5%) é um caso isolado e restringe-se a campos estruturais que não impactam as variáveis críticas do modelo, garantindo que a qualidade informacional para as etapas de predição permaneça preservada.

Esses resultados indicam alta qualidade estrutural do dataset.

1.6 Resultado Final

Após o processo de limpeza, a base de dados consolidada apresenta consistência estrutural entre os diferentes voos, livre de colunas redundantes ou variáveis sem variância (colunas mortas). A integridade temporal foi priorizada, garantindo que a cronologia dos eventos fosse mantida, mesmo com o tratamento de dados ausentes, que agora apresentam níveis residuais e controlados.

Com essa higienização, o conjunto de dados está validado para as próximas fases do projeto. O foco agora recai sobre a engenharia de variáveis físicas e a consolidação dos períodos de voo, que são etapas essenciais para alimentar os modelos de detecção de anomalias e as análises comparativas entre os diferentes padrões de falha identificados.