

Detecção de Anomalias Dinâmicas em Drones a partir de Odometria

March 18, 2026

1 Objetivo

O objetivo deste trabalho foi desenvolver um método para detectar anomalias em voos de drones utilizando exclusivamente dados de odometria (posição e velocidade), sem acesso a sensores internos.

A ideia central é tratar o movimento do drone como um sistema dinâmico observável e identificar desvios no comportamento da trajetória ao longo do tempo.

2 Pipeline

O pipeline implementado consiste nas seguintes etapas:

1. Consolidação dos dados por voo
2. Construção de variáveis cinemáticas
3. Definição de uma métrica de curvatura da trajetória
4. Detecção de anomalias via estatística robusta
5. Agregação de métricas por voo

3 Dados

Foram analisados 47 voos do dataset ALFA. Para cada voo, foram utilizados:

- posição (x, y, z) ,
- velocidade (v_x, v_y, v_z) ,
- timestamps.

Os dados foram sincronizados e organizados em arquivos consolidados por voo.

4 Modelagem Dinâmica

A análise foi conduzida no plano horizontal (x, y) , onde o comportamento dinâmico é mais evidente.

4.1 Velocidade e aceleração

A partir das velocidades, foram calculadas derivadas numéricas:

$$a_x = \frac{dv_x}{dt}, \quad a_y = \frac{dv_y}{dt}$$

Essas variáveis capturam variações no movimento ao longo do tempo.

4.2 Proxy de taxa de rotação

Foi definida uma variável central do modelo:

$$\text{yaw_rate_proxy} = \frac{v_x a_y - v_y a_x}{v_x^2 + v_y^2 + \varepsilon}$$

Essa expressão representa uma estimativa da curvatura instantânea da trajetória. Essa variável mede o quanto o drone está curvando, a intensidade de mudanças de direção, a necessidade de correção lateral. Ela tem uma utilidade particular porque responde a mudanças dinâmicas, independe de sensores internos, captura comportamento de controle do sistema.

5 Detecção de Anomalias

Para identificar desvios, foi utilizado um z-score robusto baseado em mediana e MAD:

$$z_{\text{robust}} = 0.6745 \cdot \frac{x - \text{mediana}(x)}{\text{MAD}(x)}$$

Essa abordagem é menos sensível a outliers do que o z-score tradicional.

5.1 Critério de anomalia

Um ponto foi considerado anômalo quando:

$$|z_{\text{robust}}| > \text{threshold}$$

com threshold definido como 3.0.

6 Métricas por Voo

Para cada voo, foram calculadas duas métricas principais que permitem transformar séries temporais em indicadores globais.

- **anomaly_rate**: fração de pontos anômalos
- **max_abs_z**: maior desvio observado

7 Resultados

Os voos foram agrupados em categorias:

- `engine_failure`
- `no_failure`
- `no_ground_truth`

- other

Foram gerados histogramas de:

- taxa de anomalias (`anomaly_rate`),
- intensidade máxima (`max_abs_z`).

8 Interpretação dos Resultados

As métricas indicam que diferentes tipos de voo apresentam padrões distintos de anomalia, falhas podem se manifestar como mudanças na curvatura da trajetória. Comportamentos anômalos não são necessariamente frequentes, mas podem ser intensos.

9 Importância das Variáveis

- **Velocidade** (v_x, v_y): base para toda a modelagem dinâmica.
- **Aceleração** (a_x, a_y): captura variações temporais e respostas do sistema.
- **Yaw rate proxy**: principal indicador de curvatura e comportamento dinâmico.
- **Z-score robusto**: permite detectar desvios de forma estável.
- **Anomaly rate**: mede frequência de comportamento anômalo.
- **Max abs z**: mede intensidade máxima das anomalias.

10 Conclusões

É possível detectar anomalias em voos utilizando apenas odometria. Neste caso, a curvatura da trajetória é uma variável chave para identificar comportamento anômalo. Para tal finalidade, utilizamos a abordagem baseada em estatística robusta, que é adequada para dados reais com ruído. Neste caso, estamos comparando os voos de forma quantitativa.

11 Limitações

O modelo ainda apresenta limitações. Ele não identifica diretamente a causa da anomalia e a análise a ser feita depende da qualidade da derivação numérica. O método não distingue automaticamente tipos diferentes de falha.