

Análise Inicial do Dataset ALFA e Modelagem Física de um Único Voo

1 Introdução

Iniciamos nossa primeira exploração do dataset ALFA. A proposta desta etapa foi compreender a estrutura dos arquivos, identificar as principais variáveis físicas disponíveis e construir uma base de dados consolidada que permita análises posteriores.

Inicialmente analisamos um único voo do conjunto de voos disponíveis. Trabalhar inicialmente com apenas um voo permite compreender o comportamento das variáveis e validar os procedimentos de processamento antes de expandir a análise para um maior número de voos ou ainda para todo o conjunto de voos.

2 Seleção de um Voo para Análise

Para a análise inicial foi selecionado um voo específico do conjunto de dados. Os voos do dataset estão organizados em subpastas dentro do diretório principal. No script, primeiro listamos todas essas pastas e ignoramos diretórios auxiliares (como relatórios). Em seguida, selecionamos automaticamente o primeiro voo da lista apenas para iniciar a análise exploratória e testar o pipeline de leitura, consolidação e análise dos dados. Depois de validado o procedimento, o mesmo processo pode ser aplicado aos demais voos do dataset.

Cada pasta de voo contém diversos arquivos CSV associados a diferentes sensores e mensagens do sistema ROS. Utilizamos dois arquivos nessa etapa da análise, os arquivos referentes aos dados da bateria do drone e também aos dados de posição e velocidade estimados pelo sistema de navegação.

3 Construção de uma Base de Dados

O maior desafio inicial foi lidar com os timestamps independentes de cada sensor. Para cruzar a telemetria da bateria com os dados de navegação, normalizamos o tempo para segundos decorridos e aplicamos um `merge_asof`. Definimos uma tolerância de 250ms para garantir que a posição do drone estivesse sincronizada com o estado da bateria no mesmo instante físico. Durante essa etapa, filtramos apenas o essencial: coordenadas (x, y, z) , velocidades lineares e angulares, além da tensão e corrente. Aqui surgiu um imprevisto: o voo selecionado apresentava leitura zerada de tensão. Por conta disso, adaptamos a análise para focar em um

”indicador de esforço” baseado puramente na magnitude da velocidade, permitindo seguir com a validação do pipeline mesmo sem os dados elétricos completos.

3.1 Velocidade total

A velocidade total do drone foi definida como

$$v = \sqrt{v_x^2 + v_y^2 + v_z^2}$$

3.2 Velocidade horizontal

A componente horizontal da velocidade foi definida como

$$v_h = \sqrt{v_x^2 + v_y^2}$$

Essa variável permite analisar o movimento do drone no plano horizontal.

3.3 Potência elétrica

A potência consumida pela bateria foi estimada como

$$P = V \cdot I$$

onde V representa a tensão da bateria e I a corrente elétrica.

Tentamos estimar o esforço do sistema usando potência elétrica da bateria, mas os dados de tensão estavam zerados nesse voo específico selecionado. Então definimos um indicador alternativo baseado na magnitude da velocidade do drone, que funciona como uma medida cinemática do esforço do sistema.

3.4 Esforço do sistema

Foi definido um indicador simples de esforço do sistema baseado na magnitude da velocidade:

$$effort = \sqrt{v_x^2 + v_y^2 + v_z^2}$$

Esse indicador fornece uma medida aproximada da intensidade do movimento do drone.

4 Análise Exploratória do Voo

Com a base consolidada, realizamos uma análise exploratória inicial.

Foram produzidos gráficos relacionando variáveis importantes do voo, como velocidade horizontal & velocidade vertical, evolução temporal das velocidades e trajetória do drone no plano XY .

Essas visualizações permitem identificar padrões básicos de movimento, como fases de subida, descida e deslocamento horizontal.

5 Estimativa de Deriva Lateral

Para compreender o impacto de distúrbios externos, como vento lateral, decomposemos a velocidade em componentes longitudinal (direção do movimento) e perpendicular. A componente perpendicular foi utilizada como proxy para a deriva lateral do drone. Para mitigar ruídos de alta frequência e identificar tendências reais de instabilidade de controle, aplicamos uma média móvel sobre esses valores para isolar a tendência da deriva lateral, possivelmente causada por vento ou instabilidades de controle, de ruídos momentâneos.

6 Curvatura da Trajetória

Foi também calculado um indicador relacionado à curvatura da trajetória do drone. Esse indicador foi obtido a partir das velocidades e acelerações no plano horizontal:

$$\omega \approx \frac{v_x a_y - v_y a_x}{v_x^2 + v_y^2}$$

Esse termo funciona como um proxy da taxa de rotação da trajetória.

Valores elevados desse indicador podem indicar, entre outros, manobras bruscas, instabilidades e perturbações externas.

7 Detecção de Eventos Incomuns

Utilizamos estatística robusta para detectar anomalias. Em vez de usar média e desvio padrão, utilizamos a mediana e o MAD (desvio absoluto mediano), que são menos sensíveis a valores extremos. Isso permite identificar eventos raros no voo sem que picos isolados distorçam a análise.

Inicialmente foi calculado o valor mediano da variável de curvatura da trajetória. Em seguida foi estimado o desvio absoluto mediano (MAD). A partir dessas quantidades foi construído o seguinte score.

$$z = 0.6745 \frac{x - \text{mediana}}{MAD}$$

A fórmula acima é a forma conhecida como z-score robusto. O fator 0.6745 é uma constante usada para tornar o MAD comparável ao desvio padrão quando os dados seguem aproximadamente uma distribuição normal. Dessa forma, conseguimos medir quão distante um valor está do comportamento típico do sistema sem que valores extremos distorçam a análise. Valores absolutos de z superiores a um determinado limiar foram classificados como eventos incomuns.

Esse procedimento permite identificar pontos do voo que apresentam comportamento significativamente diferente do padrão observado.

8 Conclusão

Nesta etapa inicial realizamos o primeiro processamento e exploração do dataset ALFA, acessamos e organizamos os dados, construímos uma base consolidada de variáveis físicas, criamos variáveis derivadas relevantes para a dinâmica de voo, exploramos um voo específico e implementamos um detector simples de eventos raros.

Os resultados obtidos mostram que o dataset permite estudar aspectos físicos do comportamento do drone, incluindo dinâmica de movimento e possíveis perturbações externas.

Nas próximas etapas do trabalho a análise será expandida para um número maior de voos, permitindo construir modelos estatísticos e físicos mais robustos para detecção de anomalias.