

# Base de Dados ALFA (Processed): Estrutura, Sensores e Conteúdo

Relatório descritivo

11 de fevereiro de 2026

## 1 Resumo

Este documento descreve o conteúdo da base de dados **ALFA** (versão *processed*), com foco no que está efetivamente disponível em arquivos `.csv`, como os dados estão organizados, quais são os sensores/tópicos mais frequentes, quais metadados aparecem em quase todos os arquivos e como interpretar as principais colunas. Também registramos estatísticas básicas do dataset (quantidade de arquivos, quantidade de voos, classes de voo, taxas de amostragem típicas) e pontos práticos para análise: sincronização temporal, completude dos sinais, e cuidados com valores ausentes.

## 2 Visão geral do dataset

A base ALFA, na pasta *processed*, está estruturada como um conjunto de voos (trilhas/experimentos) de uma plataforma aérea, onde cada voo é composto por vários arquivos `.csv` correspondentes a diferentes tópicos (sensores, telemetria e estado do sistema). Em geral, cada arquivo representa um fluxo temporal de uma mensagem/tópico (estilo MAVROS/ROS), registrado ao longo do voo.

### 2.1 Estatísticas gerais (a partir do índice gerado)

Com base na indexação do diretório `/content/drive/MyDrive/datasets/ALFA/processed`, obtivemos:

- **Total de CSVs encontrados:** 3180
- **Voos únicos identificados:** 47
- **Distribuição de voos por “tipo” (via nome do voo):** 46 rotulados como falha e 1 como sem *ground truth* (“no\_ground\_truth”).

A marcação “falha” foi inferida pelo padrão do nome do voo (por exemplo, `engine_failure`, `aileron_failure`, etc.). Essa marcação é útil para estudo supervisionado, mas deve ser tratada como **rótulo operacional** e não como diagnóstico absoluto.

## 3 Estrutura de diretórios e nomenclatura

### 3.1 Pastas relevantes no Drive

Neste trabalho, os dados foram lidos a partir do caminho:

```
/content/drive/MyDrive/datasets/ALFA/processed/processed/
```

### 3.2 Identificação de voo (flight\_id)

Cada voo aparece como uma pasta com um identificador do tipo:

```
carbonZ_YYYY-MM-DD-hh-mm-ss_<descriptor_do_evento>
```

Exemplos típicos:

- carbonZ\_2018-07-18-15-53-31\_1\_engine\_failure
- carbonZ\_2018-09-11-17-55-30\_1\_right\_aileron\_failure
- carbonZ\_2018-07-18-12-10-11\_no\_ground\_truth

### 3.3 Arquivos por voo

Dentro de cada pasta de voo, existem dezenas de `.csv`. O nome do arquivo tende a seguir o padrão:

```
<flight_id>-<sensor_topic>.csv
```

onde `sensor_topic` indica o tópico/sensor (por exemplo, `mavros-battery`, `mavros-rc-out`, etc.).

## 4 Arquivos auxiliares gerados na etapa de exploração

Para tornar o dataset auditável e reproduzível, foram geradas tabelas `.csv` de **índice** e **sumários**:

### 4.1 Índice do dataset

```
/content/drive/MyDrive/ALFA_processed/alfa_dataset_index.csv
```

Este índice registra, para cada arquivo:

- `flight_id`: identificador do voo;
- `is_failure`: indicação (boolean) derivada do nome;
- `csv_path`: caminho completo no Drive;
- `file`: nome do arquivo;
- `loaded`: se a leitura foi bem sucedida;
- `sep, encoding`: separador e codificação detectados;
- `n_cols`: número de colunas;
- `columns`: lista de colunas.

### 4.2 Tabelas do relatório

As tabelas do relatório estatístico foram salvas em:

```
/content/drive/MyDrive/ALFA_processed/report_tables/
```

Arquivos gerados (principais):

- `dataset_summary.csv`
- `files_by_flight.csv`

- `flights_by_class.csv`
- `sensor_topics_counts.csv`
- `time_stats_all_targets.csv`
- `time_stats_summary_by_class.csv`
- `time_stats_summary_by_sensor.csv`
- `flight_features_table.csv`

## 5 Classes de voo utilizando o padrão de nome

Uma categorização prática (usada no relatório) foi agrupar voos pelo tipo de falha descrito no nome do `flight_id`. No conjunto identificado, apareceram as classes:

- `no_ground_truth` (1 voo)
- `failure_engine` (23 voos)
- `failure_aileron` (7 voos)
- `failure_rudder` (3 voos)
- `failure_control_surfaces_mix` (1 voo)
- `failure_other` (12 voos)

Essa classificação é útil para:

- comparar padrões temporais entre falhas diferentes;
- construir modelos supervisionados (classificação por tipo de falha);
- avaliar assinaturas (features) que se repetem em um mesmo tipo.

## 6 Tópicos/sensores disponíveis considerando o subconjunto analisado

Embora o dataset completo tenha muitos tópicos, foi selecionado um conjunto de sensores com alta frequência e boa cobertura entre voos. Os sensores analisados incluem:

- `diagnostics`
- `mavros-battery`
- `mavros-imu-data`
- `mavros-imu-data_raw`
- `mavros-local_position-odom`
- `mavros-local_position-velocity`
- `mavros-global_position-global`
- `mavros-global_position-local`
- `mavros-global_position-raw-fix`
- `mavros-rc-in`
- `mavros-rc-out`

## 6.1 Frequência (tópicos mais comuns no dataset)

No ranking de `sensor_topic` mais frequentes, aparecem com alta incidência: `diagnostics`, `mavros-battery`, `mavros-imu-data_raw`, `mavros-global_position-raw-fix`, `mavros-local_position-velocity`, `mavros-rc-in`, `mavros-rc-out`, etc.

## 7 Estrutura padrão das colunas

### 7.1 Coluna de tempo (%time)

A maioria dos arquivos possui a coluna `%time`, que representa o timestamp do registro (em geral em **nanosegundos**). Em análises temporais, é comum converter para segundos e normalizar pelo início do voo:

$$t = \frac{\%time - \%time_0}{10^9}. \quad (1)$$

### 7.2 Cabeçalho ROS/MAVROS

Vários tópicos incluem um bloco padrão de metadados:

- `field.header.seq`: contador sequencial da mensagem;
- `field.header.stamp`: timestamp do header;
- `field.header.frame_id`: frame de referência (ex.: `map`).

Esses campos são úteis para:

- identificar perda de mensagens (saltos em `seq`);
- comparar relógios (diferença entre `%time` e `header.stamp`);
- garantir consistência do frame.

## 8 Exemplos de tópicos e suas colunas

A seguir, descrevemos três tópicos exemplares (extraídos de um voo) para ilustrar o conteúdo típico.

### 8.1 `mavros-battery`

Exemplo de arquivo:

```
<flight_id>-mavros-battery.csv
```

Colunas usuais:

- `field.voltage`: tensão (V), quando disponível;
- `field.current`: corrente (A), quando disponível;
- `field.charge`, `field.capacity`, `field.design_capacity`: indicadores de carga/capacidade;
- `field.percentage`: estimativa de nível de bateria;
- `field.power_supply_status/health/technology`: estado/saúde/tecnologia reportados;
- `field.present`: flag de presença;

- `field.serial_number`, `field.location`: identificação.

Em alguns voos, `field.voltage` pode aparecer com muitos valores ausentes (NaN) e outros campos podem permanecer quase constantes. Portanto, além de média e desvio-padrão. Seria recomendado que medíssemos a **completude** (fração de valores válidos) e **variabilidade** (se o sinal realmente muda ao longo do tempo).

## 8.2 mavros-rc-out

Exemplo de arquivo:

```
<flight_id>-mavros-rc-out.csv
```

Colunas usuais:

- `field.channels0 ... field.channels7`: canais do comando/saída RC (valores típicos na faixa 1000–2000, dependendo do mapeamento).

Interpretação:

- esses canais refletem comandos/atuidores (por exemplo, throttle, aileron, elevator, rudder, modos, etc.), mas a associação exata canal→função depende da configuração do veículo e do autopiloto;
- para análise estatística, é comum extrair:
  - variância por canal (atividade do comando);
  - média de  $|\Delta u|$  (mudança média entre amostras);
  - detecção de saturação/“travamento” (canal constante por longos períodos).

Observação prática: é frequente que um canal específico esteja vazio (por exemplo, `channels0` com NaN) enquanto outros possuem dados válidos. Nesses casos, a extração de features deve selecionar o canal mais informativo (maior fração de valores válidos e/ou maior variância).

## 8.3 mavros-local\_position-velocity

Exemplo de arquivo:

```
<flight_id>-mavros-local_position-velocity.csv
```

Colunas usuais:

- `field.twist.linear.x`, `field.twist.linear.y`, `field.twist.linear.z`: velocidade linear (m/s) no frame local;
- `field.twist.angular.x`, `field.twist.angular.y`, `field.twist.angular.z`: velocidade angular (rad/s), quando disponível/consistente.

Uma feature padrão é o módulo da velocidade:

$$v = \sqrt{v_x^2 + v_y^2 + v_z^2}. \quad (2)$$

Em tarefas de detecção de anomalia e falha, estatísticas como  $\bar{v}$ ,  $\sigma_v$ , picos e mudanças abruptas costumam ser informativas.

## 9 Estatísticas temporais e taxas de amostragem

O dataset contém tópicos em **diferentes taxas de amostragem**, o que é esperado em telemetria real. No subconjunto analisado, as medianas estimadas da frequência por tópico foram aproximadamente:

Tabela 1: Frequência mediana por tópico no subconjunto analisado.

| <b>sensor_topic</b>            | <b>mediana <math>f_s</math> (Hz)</b> |
|--------------------------------|--------------------------------------|
| mavros-battery                 | 20.38                                |
| mavros-imu-data_raw            | 10.00                                |
| mavros-global_position-raw-fix | 5.00                                 |
| mavros-local_position-velocity | 4.12                                 |
| mavros-local_position-odom     | 4.12                                 |
| mavros-global_position-local   | 4.12                                 |
| mavros-global_position-global  | 4.12                                 |
| mavros-rc-in                   | 2.99                                 |
| mavros-rc-out                  | 2.99                                 |
| mavros-imu-data                | 2.54                                 |
| diagnostics                    | 0.76                                 |

## 10 Completude e consistência

Um ponto positivo observado foi a **cobertura** dos sensores-alvo: no recorte onde exigimos simultaneamente os tópicos listados, a contagem indicou que **47/47 voos** possuem esses sensores no índice analisado. Isso facilita comparações entre voos.

Entretanto, “ter arquivo” não garante “ter sinal útil”. Por isso, para cada coluna numérica relevante, recomenda-se registrar:

- **fração de valores válidos** (não-NaN);
- **variabilidade** (desvio-padrão, variância, quantis);
- **travamentos** (valores constantes por longos trechos);
- **outliers** (picos que podem ser falhas reais ou artefatos de log).

## 11 Tabela de features por voo

Foi gerada uma tabela consolidada por voo:

`/content/drive/MyDrive/ALFA_processed/report_tables/flight_features_table.csv`

Essa tabela contém, por `flight_id`, um conjunto de métricas agregadas que podem ser usadas diretamente em modelos de classificação/anomalia. Citamos aqui alguns exemplos de colunas:

- `duration_s`: duração estimada do voo;
- `bateria`: médias e desvios de tensão/corrente;
- `rc_out_var`, `rc_out_absdiff_mean`: indicadores de atividade dos comandos;
- `speed_mean`, `speed_std`: estatísticas de velocidade (quando computável).

Se algumas colunas agregadas aparecem como zero ou NaN em certos voos, isso normalmente indica ausência de dados válidos no sinal original (por exemplo, tensão com NaN), escolha de canal RC vazio, ou necessidade de converter strings para numérico antes do cálculo.

## 12 Resumo de interpretação

O dataset pode ser apresentado considerando essas ideias:

- **Um voo = uma pasta = vários CSVs**, cada CSV é um tópico/sensor.
- **%time** é o eixo do tempo; quase tudo é série temporal.
- Cada tópico pode ter **taxa de amostragem diferente**.
- Há campos “padrão” do header (seq/stamp/frame\_id) que ajudam na auditoria.
- **Cobertura alta** de sensores-alvo nos 47 voos, o que facilita comparação.
- **Sinal útil vs. arquivo presente**: é necessário checar NaN, travamentos e variância.
- A base permite tanto análise por janela (tempo real) quanto por voo (resumo).

## 13 Conclusão

A base ALFA (processed) é um conjunto consistente de voos com telemetria multi-sensor, organizado por pastas de voo e arquivos por tópico. A estrutura facilita a construção de pipelines reproduzíveis: índice geral do dataset, sumários por sensor e por classe, estatísticas temporais e extração de features por voo. O ponto central para trabalhar com robustez é tratar corretamente tempo, re-amostragem e completude dos sinais, pois alguns tópicos podem existir mas conter valores ausentes ou pouco informativos em determinados voos.